

# AI 的未來與機器學習的基石

姓名：鄭凱謙  
學號：313653003

## 1 AI 的未來能力

### 1.1 願景：全天候 AI 適性化家教系統

目前的線上學習平台大多是「單向」且「標準化」的。老師預先錄製好影片，所有學生觀看相同的內容、做一樣的習題。系統無法真正區分一個學生是「粗心算錯」還是「核心觀念不懂」，缺乏真人家教的即時反饋和策略調整能力。

我設想 20 年後的 AI 能力，將是「全天候的 AI 適性化家教系統」。這是一個高度個人化的學習夥伴，能透過分析學生的作答紀錄、語音語調、甚至表情，來即時推論學生的學習狀態、情緒波動和知識盲點。

### 1.2 具體應用場景

- 即時觀念釐清：當學生在寫物理作業卡住時，AI 不會直接給答案，而是判斷出他對「力矩」觀念不熟。AI 立刻生成一個他感興趣的「蹺蹺板」例子，用 30 秒的動畫幫他釐清觀念。
- 高效複習計畫：AI 知道學生 A 擅長圖像記憶、學生 B 擅長邏輯推導。在準備期末考時，AI 會給學生 A 一份「心智圖」，並給學生 B 一份「公式推導」練習題，真正實現因材施教。

### 1.3 重要性

這項能力的重要性在於實現「教育平權」。它能將老師從重複性的批改工作中解放出來，專注於學生的心理與品格發展；同時讓偏鄉或資源不足的學生，也能享受到與都市學生同等品質的「一對一」頂級教學資源。

## 2 所需的成分與資源

為了實現上述宏大的願景，我們需要整合以下關鍵成分，這些成分在系統中相互依存：

### 2.1 多模態感知資料

要達到「家教級」的觀察力，僅靠答題紀錄是不夠的。系統需要整合視覺數據（透過攝像頭捕捉困惑、專注或挫折的面部微表情）、聽覺數據（語音提問的語調與停頓）以及行為數據（滑鼠軌跡、猶豫時間）。此外，需要極大規模的縱向學習歷程數據，以捕捉學生長期的成長軌跡。

## 2.2 核心計算工具

- 知識圖譜：用於構建學科知識的拓撲結構，AI 必須知道「解聯立方程式」的前置技能是「一元一次方程式」，才能進行有效的診斷與導航。
- 因果推論：區分相關性與因果性。學生答錯是因為「不懂」還是「粗心」？這需要因果模型來判斷。
- 生成式模型：用於即時生成個人化的解釋、例題或圖像（如上述的蹺蹺板動畫）。

## 2.3 學習架構

- **Meta-Learning (元學習)**：每個學生的學習風格不同，AI 需要具備「學會如何學習」的能力，利用過去的經驗快速適應新學生的特質。
- **Human-in-the-loop RL**：教學目標不僅是分數，還包含激發興趣，需要將人類專家的評估納入獎勵函數設計。

# 3 涉及的機器學習類型

本系統的核心運作邏輯，是結合 監督式學習與 強化學習的雙引擎架構。

## 3.1 監督式學習：負責「診斷」

- 角色：AI 系統必須先具備「了解學生」的能力，建立準確的學生模型 (Student Model)。
- 資料來源：學生的歷史作答紀錄、線上互動行為。
- 目標訊號：預測學生在特定題目上的「答對機率」(二元分類) 或未來的「測驗分數」(迴歸)。

## 3.2 強化學習：負責「決策」

- 角色：AI 必須動態地「決定下一步該做什麼」。這是一個序列決策過程，AI 必須學習一套最佳教學策略。
- 環境互動：學生即為環境。AI 的教學動作會改變學生的狀態。
- 目標訊號 (Reward)：最大化學生的「長期學習成效」與「學習動機」，這比單純的答對下一題更為複雜。

# 4 第一步的「可實作模型問題」

為了驗證上述概念，我將宏大願景縮小為一個目前可實作的簡化控制問題。

## 4.1 問題設計

- 簡化目標：從「全科全天候家教」簡化為「國中數學二元一次方程式」的單一單元教學。
- 任務目標：動態調整題目難度，使學生始終處於「心流通道 (Flow Zone)」，定義為預期答對率約 70%。
- 輸入 (Input)：當前題目難度  $D_t$  與學生作答結果  $R_t$  (0 或 1)。
- 輸出 (Action)：下一題的題目難度  $D_{t+1}$  (從題庫  $[-2, -1, 0, 1, 2]$  中選擇)。

## 4.2 模型與方法

- 模型選擇：SGD Classifier (Logistic Regression)
  - 理由 1：數學對應性。教育心理學中的項目反應理論 (IRT) 指出，學生答對機率  $P(\theta)$  與能力  $\theta$ 、難度  $b$  的關係為 Sigmoid 函數：

$$P(\theta) = \frac{1}{1 + e^{-(\theta-b)}} \quad (1)$$

這與邏輯迴歸的數學形式完全一致，因此 Logistic Regression 非常適合用來建模「學生能力」與「答對率」的關係。

- 理由 2：線上學習 (Online Learning)。學生的能力在練習過程中會不斷改變 (進步)，傳統的批次訓練 (Batch Training) 無法適應這種動態環境。我使用 `partial_fit` 方法，讓模型每做一題就更新一次參數，即時捕捉學生的能力變化。
- 策略選擇：Target Probability Policy
  - AI 不僅僅是預測，還需要決策。策略邏輯是計算當前題庫中所有難度的預期答對率，並選擇最接近 0.7 (70%) 的難度作為下一題。

## 4.3 實作結果與分析

使用 Python 建立模擬環境並進行 150 題的教學模擬，結果如圖 1 所示。

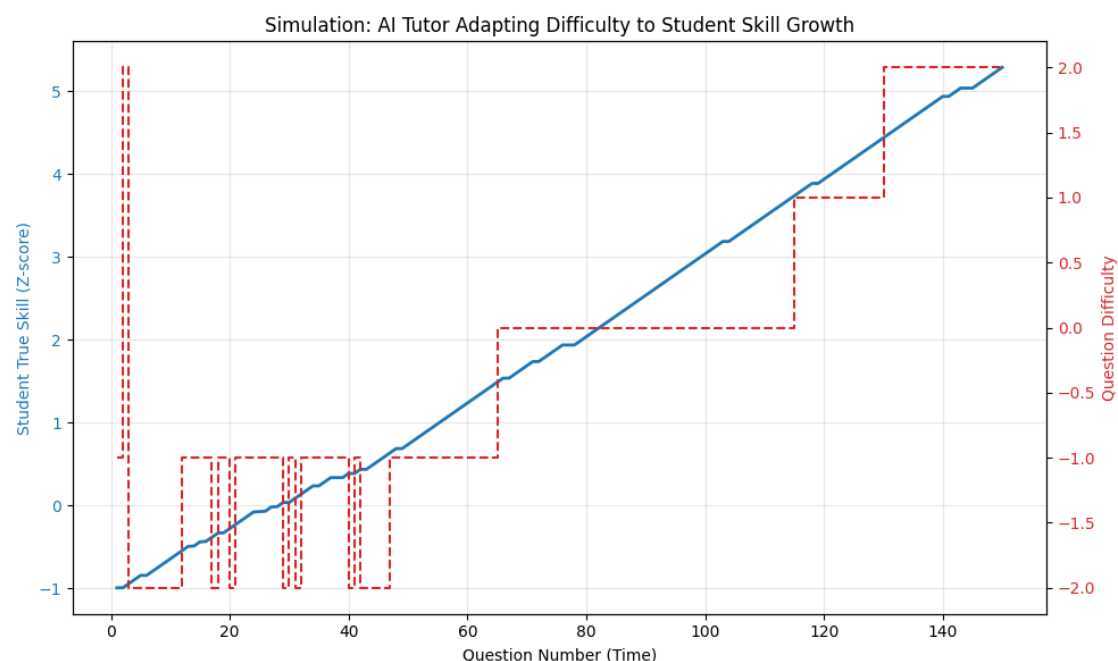


Figure 1: 模擬結果：AI 家教隨學生能力成長動態調整題目難度（藍線為學生能力，紅虛線為題目難度）

圖表分析：

- 藍線 (Student Skill)：顯示學生真實能力隨著練習從 -1.0 逐步成長到 5.0 以上。
- 紅虛線 (Question Difficulty)：AI 指派的難度呈現明顯的「階梯狀上升」。在暖身期 (0-65 題) 鎖定簡單題目 (-1.0)；隨著能力提升，AI 自動在精熟期 (130 題後) 將難度調升至最高。
- 註記：圖表採用雙軸顯示。若比較絕對數值 (Z-score)，學生能力在許多時刻顯著高於題目難度，這證實了「模型滯後」現象的存在。

#### 4.4 討論

透過這個模型，我獲得了兩個關鍵洞察：

1. 模型滯後的穩定機制：實驗發現 AI 的難度調整總是滯後於學生的真實能力成長。這是因為 AI 需要累積足夠的「答對證據」才能更新參數。這在無意中形成了一種「鞏固期」，避免學生剛學會就立刻遭遇過大挫折。
2. 冷啟動 (Cold Start) 挑戰：模擬初期 AI 的難度選擇波動較大。這揭示了未來大問題中的關鍵困難：如何在極少的互動內快速掌握新學生的特性？這證實了未來系統需要引入 Meta-Learning 或 Transfer Learning 技術的必要性。